main

June 26, 2021

NB. : see Readme for installation instructions

1 Concours Data is for Good : aidons Paris à devenir une smart-city !

1.1 Contexte

Dans le cadre du programme "Végétalisons la ville" organisé par la ville de Paris, nous proposons ici une analyse exploratoire des données OpenData concernant les arbres gérés par la ville de Paris.

L'objectif est d'aider Paris à devenir une "Smart-City" en gérant ses arbres de la manière la plus responsable possible. C'est-à-dire en optimisant les trajets nécessaires pour entretenir ces arbres.

1.2 Outils utilisés

Nous allons utiliser le langage Python, et présenter ici le code, les résultats et l'analyse sous forme de Notebook Jupyter.

Nous allons aussi utiliser les bibliothèques usuelles d'exploration et analyse de données, afin d'améliorer la simplicité et la performance de notre code : * NumPy et Pandas : effectuer des calculs scientifiques (statistiques, algèbre, ...) et manipuler des séries et tableaux de données volumineuses et complexes * Matplotlib, Pyplot, Seaborn et Plotly : générer des graphiques lisibles, intéractifs et pertinents

[1]:
```
# Import libraries
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import plotly.express as px
import plotly.graph_objects as go
from plotly.subplots import make_subplots

## If you use Notebook (and not JupyterLab), uncomment following lines
# import plotly.io as pio
# pio.renderers.default='notebook'
```

1.3 Chargement des données et premier aperçu

Les données mises à disposition sont issues de opendata.paris.fr et représentent "l'ensemble des arbres, ainsi que les arbres d'alignement, présents sur le territoire parisien et des cimetières extra-muros (hors de Paris)."

Nous allons dans un premier temps simplement charger les données en mémoire et observer quelques valeurs.

[2]:
```
# load raw data into a Pandas DataFrame, separator is ";"
raw_data = pd.read_csv("https://s3-eu-west-1.amazonaws.com/static.oc-static.com/
↪prod/courses/files/AI+Engineer/
↪Project+2+Participez+%C3%A0+un+concours+sur+la+Smart+City/p2-arbres-fr.csv",␣
↪sep=';')

# display first 5 rows
raw_data.head()
```

[2]:
```
      id type_emplacement domanialite   arrondissement complement_addresse  \
0  99874            Arbre      Jardin   PARIS 7E ARRDT                 NaN
1  99875            Arbre      Jardin   PARIS 7E ARRDT                 NaN
2  99876            Arbre      Jardin   PARIS 7E ARRDT                 NaN
3  99877            Arbre      Jardin   PARIS 7E ARRDT                 NaN
4  99878            Arbre      Jardin  PARIS 17E ARRDT                 NaN

   numero                                        lieu id_emplacement  \
0     NaN   MAIRIE DU 7E 116 RUE DE GRENELLE PARIS 7E             19
1     NaN   MAIRIE DU 7E 116 RUE DE GRENELLE PARIS 7E             20
2     NaN   MAIRIE DU 7E 116 RUE DE GRENELLE PARIS 7E             21
3     NaN   MAIRIE DU 7E 116 RUE DE GRENELLE PARIS 7E             22
4     NaN  PARC CLICHY-BATIGNOLLES-MARTIN LUTHER KING       000G0037

  libelle_francais      genre         espece variete  circonference_cm  \
0       Marronnier   Aesculus  hippocastanum     NaN                20
1               If      Taxus        baccata     NaN                65
2               If      Taxus        baccata     NaN                90
3           Erable       Acer        negundo     NaN                60
4     Arbre à miel  Tetradium      daniellii     NaN                38

   hauteur_m stade_developpement  remarquable  geo_point_2d_a  geo_point_2d_b
0          5                NaN          0.0       48.857620        2.320962
1          8                  A          NaN       48.857656        2.321031
2         10                  A          NaN       48.857705        2.321061
3          8                  A          NaN       48.857722        2.321006
4          0                NaN          NaN       48.890435        2.315289
```

Nous voyons que, pour chaque arbre listé, nous disposons des informations suivantes (la description des colonnes est disponible sur le site OpenData) : - `id` : simple identifiant de l'arbre (entier, ex. : `99874`) - `type_emplacement` : type de l'emplacement (texte, ex. : `"Arbre"`) - `domanialite` : type

de lieu auquel appartient l'arbre (texte, ex. : "Jardin") - arrondissement : arrondissement de Paris où est situé l'arbre (texte, ex. : "PARIS 7E ARRDT") - complement_addresse : complement d'adress (texte, pas d'exemple visible) - numero : numéro de l'adress (texte, pas d'exemple visible) - lieu : adresse de l'arbre (texte, ex. : "MAIRIE DU 7E 116 RUE DE GRENELLE PARIS 7E") - id_emplacement : identifiant de l'emplacement (texte, ex. : "19") - libelle_francais : nom commun (vernaculaire) de l'espèce de l'arbre (texte, ex. : "Marronnier") - genre : genre de l'arbre (texte, ex. : "Aesculus") - espece : espèce de l'arbre (texte, ex. : "hippocastanum") - variete : variété de l'arbre (texte, pas d'exemple visible) - circonference_cm : circonférence en centimètres de l'arbre (entier, ex. : 20) - hauteur_m : taille en mètres de l'arbre (entier, ex. : 5) - stade_developpement : stade de développement de l'arbre (texte, ex. : "A" pour "Adulte") - remarquable : si l'arbre est "remarquable" ou non (booléen, ex. : 0 pour un arbre "non remarquable") - geo_point_2d_a : latitude de la position de l'arbre (nombre à virgule, ex. : 48.857620) - geo_point_2d_b : longitude de la position de l'arbre (nombre à virgule, ex. : 2.320962)

Nous voyons déjà que parmis les quelques premières données : - un certain certain nombre de valeurs ne sont pas fournies (NaN = "Not a Number" = donnée non disponible) - nous pouvons classer les variables selon leur type : - quantitatives - discrètes : id, circonference_cm, hauteur_m - continues : geo_point_2d_a, geo_point_2d_b - qualitatives - nominales : type_emplacement, domanialite, arrondissement, complement_addresse, numero, lieu, id_emplacement, libelle_francais, genre, espece, variete - ordinales : stade_developpement, remarquable - on peut aussi les classer en trois grandes catégories, d'après leur sens : - métadonnées internes au système : id, id_emplacement, type_emplacement - données de localisation : arrondissement, complement_addresse, numero, lieu, geo_point_2d_a, geo_point_2d_b - données de description : - taille : circonference_cm, hauteur_m et stade_developpement - type : libelle_francais, genre, espece et variete - autre : remarquable

Nous allons observer plus précisément les types de valeurs et les valeurs vides :

[3]:
```
# Display data types and empty values
raw_data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200137 entries, 0 to 200136
Data columns (total 18 columns):
 #   Column               Non-Null Count   Dtype
---  ------               --------------   -----
 0   id                   200137 non-null  int64
 1   type_emplacement     200137 non-null  object
 2   domanialite          200136 non-null  object
 3   arrondissement       200137 non-null  object
 4   complement_addresse  30902 non-null   object
 5   numero               0 non-null       float64
 6   lieu                 200137 non-null  object
 7   id_emplacement       200137 non-null  object
 8   libelle_francais     198640 non-null  object
 9   genre                200121 non-null  object
 10  espece               198385 non-null  object
 11  variete              36777 non-null   object
```

```
 12  circonference_cm     200137 non-null  int64
 13  hauteur_m            200137 non-null  int64
 14  stade_developpement  132932 non-null  object
 15  remarquable          137039 non-null  float64
 16  geo_point_2d_a       200137 non-null  float64
 17  geo_point_2d_b       200137 non-null  float64
dtypes: float64(4), int64(3), object(11)
memory usage: 27.5+ MB
```

Nous voyons alors que : - la colonne `numero` n'est jamais renseignée (`Non-Null count = 0`) - ce critère n'apporte donc pas d'information - les colonnes `complement_addresse` (`Non-Null count = 30902`) et `variete` (`Non-Null count = 36777`) sont très peu renseignées (> 80% de valeurs non définies) - les informations apportées par ces colonnes seront donc très difficilement exploitables en l'état - les colonnes `stade_developpement` (`Non-Null count = 132932`) et `remarquable` (`Non-Null count = 137039`) sont partiellement renseignées (> 30% de valeurs non définies) - les informations apportées par ces colonnes seront donc pas facilement exploitables en l'état - les colonnes `libelle_francais` (`Non-Null count = 198640`) et `espece` (`Non-Null count = 198385`) sont pas toujours renseignées (> 0,5% de valeurs non définies) - les informations apportées par ces colonnes sont assez fiables, mais il faudra faire attention aux cas non renseignés

1.4 Première analyse statistique

Nous allons maintenant chercher à comprendre comment sont réparties les valeurs pour chaque caractéristique de nos arbres.

Une simple description statistique de chaque colonne nous donne les informations suivantes : - pour chaque donnée numérique (`id`, `circonference_cm`, `hauteur_m`, `remarquable`, `geo_point_2d_a` et `geo_point_2d_b`), nous obtenons : - le nombre de valeurs non vides (`count`) - la moyenne (`mean`) - l'écart-type (`std`) - les valeurs minimale (`min`) et maximale (`max`) - les 25, 50 (médiane) et 75 centiles (`25%`, `50%` et `75%`)

- our chaque donnée textuelle (`type_emplacement`, `domanialite`, `arrondissement`, `complement_addresse`, `lieu`, `id_emplacement`, `libelle_francais`, `genre`, `espece`, `variete` et `stade_developpement`), nous obtenons :
  - le nombre de valeurs non vides (`count`)
  - le nombre de valeurs différentes (`unique`)
  - la valeur la plus représentée (`top`)
  - la fréquence de la valeur la plus représentée (`freq`)

[4]:
```
# Display statistical summary of each column
raw_data.describe(include="all")
```

[4]:

	id	type_emplacement	domanialite	arrondissement
count	2.001370e+05	200137	200136	200137
unique	NaN	1	9	25
top	NaN	Arbre	Alignement	PARIS 15E ARRDT
freq	NaN	200137	104949	17151
mean	3.872027e+05	NaN	NaN	NaN
std	5.456032e+05	NaN	NaN	NaN

```
min     9.987400e+04              NaN         NaN              NaN
25%     1.559270e+05              NaN         NaN              NaN
50%     2.210780e+05              NaN         NaN              NaN
75%     2.741020e+05              NaN         NaN              NaN
max     2.024745e+06              NaN         NaN              NaN

       complement_addresse  numero  \
count                30902     0.0
unique                3795     NaN
top                    SN°     NaN
freq                   557     NaN
mean                   NaN     NaN
std                    NaN     NaN
min                    NaN     NaN
25%                    NaN     NaN
50%                    NaN     NaN
75%                    NaN     NaN
max                    NaN     NaN

                                          lieu id_emplacement  \
count                                   200137         200137
unique                                    6921          69040
top     PARC FLORAL DE PARIS / ROUTE DE LA PYRAMIDE         101001
freq                                      2995           1324
mean                                       NaN            NaN
std                                        NaN            NaN
min                                        NaN            NaN
25%                                        NaN            NaN
50%                                        NaN            NaN
75%                                        NaN            NaN
max                                        NaN            NaN

       libelle_francais     genre       espece     variete  circonference_cm  \
count            198640    200121       198385       36777     200137.000000
unique              192       175          539         436               NaN
top             Platane  Platanus  x hispanica  Baumannii'               NaN
freq              42508     42591        36409        4538               NaN
mean                NaN       NaN          NaN         NaN         83.380479
std                 NaN       NaN          NaN         NaN        673.190213
min                 NaN       NaN          NaN         NaN          0.000000
25%                 NaN       NaN          NaN         NaN         30.000000
50%                 NaN       NaN          NaN         NaN         70.000000
75%                 NaN       NaN          NaN         NaN        115.000000
max                 NaN       NaN          NaN         NaN     250255.000000

           hauteur_m stade_developpement    remarquable  geo_point_2d_a  \
count   200137.000000             132932  137039.000000   200137.000000
```

```
unique            NaN                  4           NaN             NaN
top               NaN                  A           NaN             NaN
freq              NaN              64438           NaN             NaN
mean        13.110509                NaN      0.001343       48.854491
std       1971.217387                NaN      0.036618        0.030234
min          0.000000                NaN      0.000000       48.742290
25%          5.000000                NaN      0.000000       48.835021
50%          8.000000                NaN      0.000000       48.854162
75%         12.000000                NaN      0.000000       48.876447
max     881818.000000                NaN      1.000000       48.911485

        geo_point_2d_b
count    200137.000000
unique             NaN
top                NaN
freq               NaN
mean          2.348208
std           0.051220
min           2.210241
25%           2.307530
50%           2.351095
75%           2.386838
max           2.469759
```

Observons maintenant la distribution empirique de chaque variable, de manière non visuelle dans un premier temps, afin de voir quels types de graphes seront ensuite le plus adaptés :

[5]:
```
# display value frequencies per column
for col in raw_data.columns:
    print(f'\n \
================================================\n \
>    { col }\n \
------------------------------------------------')

    counts = raw_data[col].value_counts()
    freq = raw_data[col].value_counts(normalize=True)
    display(pd.DataFrame({'count': counts, 'freq': freq}))
```

```
 ================================================
 >    id
 ------------------------------------------------

        count      freq
262144      1  0.000005
209715      1  0.000005
150300      1  0.000005
148253      1  0.000005
```

```
152351      1  0.000005
…       …       …
249171      1  0.000005
259412      1  0.000005
261461      1  0.000005
255318      1  0.000005
264191      1  0.000005

[200137 rows x 2 columns]
```

```
 ================================================
 >    type_emplacement
 ------------------------------------------------

        count  freq
Arbre  200137   1.0
```

```
 ================================================
 >    domanialite
 ------------------------------------------------

               count      freq
Alignement    104949  0.524388
Jardin         46262  0.231153
CIMETIERE      31926  0.159522
DASCO           6422  0.032088
PERIPHERIQUE    5327  0.026617
DJS             3900  0.019487
DFPE            1325  0.006620
DAC               21  0.000105
DASES              4  0.000020
```

```
 ================================================
 >    arrondissement
 ------------------------------------------------

                   count      freq
PARIS 15E ARRDT    17151  0.085696
PARIS 13E ARRDT    16712  0.083503
PARIS 16E ARRDT    16403  0.081959
PARIS 20E ARRDT    15340  0.076647
PARIS 19E ARRDT    13709  0.068498
PARIS 12E ARRDT    12600  0.062957
SEINE-SAINT-DENIS  11570  0.057810
BOIS DE VINCENNES  11510  0.057511
PARIS 14E ARRDT    11399  0.056956
PARIS 17E ARRDT    10762  0.053773
PARIS 18E ARRDT    10011  0.050021
```

```
PARIS 7E ARRDT      8617  0.043056
VAL-DE-MARNE        7580  0.037874
PARIS 8E ARRDT      7245  0.036200
PARIS 11E ARRDT     5658  0.028271
HAUTS-DE-SEINE      5298  0.026472
BOIS DE BOULOGNE    3978  0.019876
PARIS 10E ARRDT     3385  0.016913
PARIS 4E ARRDT      2740  0.013691
PARIS 5E ARRDT      2368  0.011832
PARIS 6E ARRDT      1764  0.008814
PARIS 1ER ARRDT     1413  0.007060
PARIS 3E ARRDT      1209  0.006041
PARIS 9E ARRDT      1167  0.005831
PARIS 2E ARRDT       548  0.002738
```

```
 ================================================
 >    complement_addresse
 ------------------------------------------------
```

```
                          count      freq
SN°                         557  0.018025
1                           552  0.017863
2                           547  0.017701
3                           498  0.016115
4                           464  0.015015
…                           …       …
panneau de signalisation      1  0.000032
face Banque de France         1  0.000032
16-7538                       1  0.000032
Face 41                       1  0.000032
f4 rue de la Corderie         1  0.000032

[3795 rows x 2 columns]
```

```
 ================================================
 >    numero
 ------------------------------------------------
```

```
Empty DataFrame
Columns: [count, freq]
Index: []
```

```
 ================================================
 >    lieu
 ------------------------------------------------
```

```
                                                  count      freq
PARC FLORAL DE PARIS / ROUTE DE LA PYRAMIDE         2995  0.014965
```

```
PARC DES BUTTES CHAUMONT                                  2331  0.011647
PARC ANDRE CITROEN                                        2095  0.010468
PARC OMNISPORT SUZANNE LENGLEN / 7 BOULEVARD DE…          1478  0.007385
INSEP / AVENUE DU TREMBLAY                                1293  0.006461
…                                                          …       …
CIMETIERE DE PANTIN / DIV 107                                1  0.000005
CIMETIERE DU PERE LACHAISE / DIV 80                          1  0.000005
ROBERT HOUDIN (16)                                           1  0.000005
VILLA POIRIER                                                1  0.000005
RUE DE L AISNE                                               1  0.000005

[6921 rows x 2 columns]


 ================================================
 >    id_emplacement
 ------------------------------------------------

              count      freq
101001         1324  0.006615
101002         1241  0.006201
101003         1128  0.005636
202001         1032  0.005156
101004         1020  0.005097
…              …        …
A03900030011      1  0.000005
000D0127          1  0.000005
A00600090006      1  0.000005
A07300071007      1  0.000005
65502012          1  0.000005

[69040 rows x 2 columns]


 ================================================
 >    libelle_francais
 ------------------------------------------------

                     count      freq
Platane              42508  0.213995
Marronnier           25207  0.126898
Tilleul              21305  0.107254
Erable               18389  0.092575
Sophora              11797  0.059389
…                    …        …
Caragana                 1  0.000005
Garrya                   1  0.000005
Jujubier                 1  0.000005
Heptacodion de Chine     1  0.000005
Sycopsis                 1  0.000005
```

[192 rows x 2 columns]

```
 ================================================
 >    genre
 ------------------------------------------------
```

	count	freq
Platanus	42591	0.212826
Aesculus	25341	0.126628
Tilia	21550	0.107685
Acer	18471	0.092299
Sophora	11830	0.059114
…	…	…
Heptacodium	1	0.000005
Cordyline	1	0.000005
Phyllanthus	1	0.000005
Enkianthus	1	0.000005
Distylium	1	0.000005

[175 rows x 2 columns]

```
 ================================================
 >    espece
 ------------------------------------------------
```

	count	freq
x hispanica	36409	0.183527
hippocastanum	20039	0.101011
japonica	11822	0.059591
n. sp.	9063	0.045684
tomentosa	8962	0.045175
…	…	…
lobata	1	0.000005
occidentalis var. reticulata	1	0.000005
pekinensis	1	0.000005
circinatum	1	0.000005
elliptica	1	0.000005

[539 rows x 2 columns]

```
 ================================================
 >    variete
 ------------------------------------------------
```

	count	freq
Baumannii'	4538	0.123392
Briotii'	2827	0.076869

```
Euchlora'        2756  0.074938
Chanticleer'     2595  0.070560
Fastigiata'      2483  0.067515
…                …       …
Dampieri'           1  0.000027
Lambertin n°1'      1  0.000027
Api Rose'           1  0.000027
Aconitifolium'      1  0.000027
Lucombeana'         1  0.000027

[436 rows x 2 columns]


 ================================================
 >    circonference_cm
 ------------------------------------------------

      count      freq
0     25867  0.129246
20     9711  0.048522
70     6780  0.033877
60     6369  0.031823
80     6206  0.031009
…     …       …
357       1  0.000005
485       1  0.000005
1125      1  0.000005
1205      1  0.000005
511       1  0.000005

[531 rows x 2 columns]


 ================================================
 >    hauteur_m
 ------------------------------------------------

      count      freq
0     39219  0.195961
10    28632  0.143062
5     26345  0.131635
15    17228  0.086081
8     13628  0.068093
…     …       …
5155      1  0.000005
218       1  0.000005
91        1  0.000005
219       1  0.000005
255       1  0.000005
```

```
[143 rows x 2 columns]


 ================================================
 >    stade_developpement
 ------------------------------------------------

    count      freq
A   64438  0.484744
JA  35444  0.266633
J   26937  0.202637
M    6113  0.045986


 ================================================
 >    remarquable
 ------------------------------------------------

      count      freq
0.0  136855  0.998657
1.0     184  0.001343


 ================================================
 >    geo_point_2d_a
 ------------------------------------------------

           count      freq
48.833321      2  0.000010
48.848812      2  0.000010
48.837168      2  0.000010
48.829912      2  0.000010
48.838318      2  0.000010
…          …       …
48.849614      1  0.000005
48.835809      1  0.000005
48.872331      1  0.000005
48.841893      1  0.000005
48.870508      1  0.000005

[200107 rows x 2 columns]


 ================================================
 >    geo_point_2d_b
 ------------------------------------------------

          count      freq
2.439665      2  0.000010
2.387348      2  0.000010
2.337371      2  0.000010
2.446277      2  0.000010
```

```
2.386442      2  0.000010
…          …       …
2.337337      1  0.000005
2.349625      1  0.000005
2.281117      1  0.000005
2.360074      1  0.000005
2.342481      1  0.000005

[200114 rows x 2 columns]
```

Nous voyons alors que : - chaque arbre possède un `id` unique - cette variable n'apporte donc aucun information - il n'y a qu'une seule valeur possible pour la variable `type_emplacement` : `"Arbre"` - ce critère n'apporte donc pas d'information - les valeurs respectives de `complement_addresse` et `id_emplacement` sont très disparates dans leur format (pas de valeurs très représentatives) et ne sont pas humainement parlantes - la colonne `lieu` peut être découpée avec le séparateur `" / "` afin de regrouper par exemple tous les lieux commenant par `"CIMETIERE DE PANTIN"` - les données de `circonference_cm` et `hauteur_m` ont des valeurs aberrantes dont il faudra tenir compte : - `minimum = 0` , ce qui semble impossible - `circonference_cm` : `maximum = 250255` et `hauteur_m` : `maximum = 881818` , ce qui semble impossible

1.5 Un peu de nettoyage

Nous allons : - supprimer les colonnes inutiles : `type_emplacement` et `numero` - renommer les valeurs de `stade_developpement` pour des valeurs plus explicites - découper la valeur de `lieu` avec le séparateur `" / "` - créer de nouvelles colonnes `top_XXX` où les valeurs les moins fréquentes seront remplacées par la valeur `"Other"` pour les colonnes `lieu`, `lieu_1`, `libelle_francais`, `genre`, `espece` et `variete`

[6]:
```
# drop useless columns
clean_data = raw_data.drop(columns=['type_emplacement','numero'])

# replace `stade_developpement` values
clean_data.stade_developpement.replace({
    'J' :'Jeune',
    'JA':'Jeune Adulte',
    'A' :'Adulte',
    'M' :'Mature',
}, inplace=True)

# extract the first part of column `lieu`
clean_data['lieu_1'] = clean_data["lieu"].str.split("/", expand=True)[0].str.
 ↪strip()
```

[7]:
```
# Display top 10 values of lieu and lieu_1
fig, (ax1, ax2) = plt.subplots(2, 1,
    figsize=(16,12),
)
```

```
clean_data['lieu'].value_counts().head(10).plot(
    kind='barh',
    ax=ax1,
    title="Top 10 lieux sans découpage ' / '",
)

clean_data['lieu_1'].value_counts().head(10).plot(
    kind='barh',
    ax=ax2,
    title="Top 10 lieux avec découpage ' / '",
)

plt.show()
```

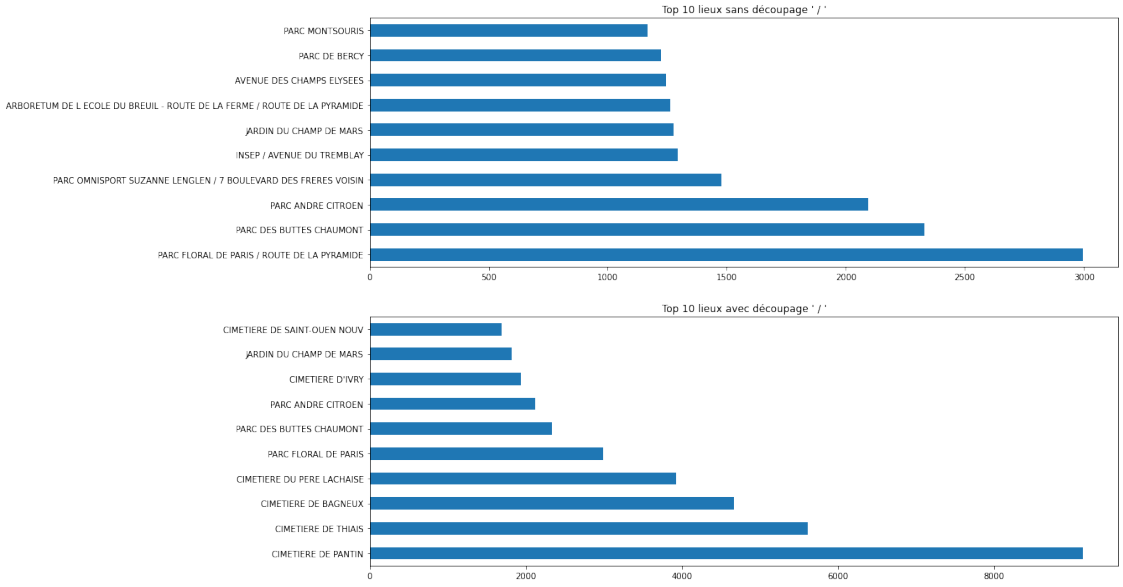

[8]:
```
# Let's keep only the top values and merge the rest into "Other"
for col in ['lieu', 'lieu_1', 'libelle_francais', 'genre', 'espece', 'variete']:
    freq = clean_data[col].value_counts()
    clean_data['top_'+col] = clean_data[col].where(
        clean_data[col].isna() | clean_data[col].isin(freq.index[:20]),
        other='Other',
    )
```

[9]:
```
# Let's see if categories are well organised
fig = px.parallel_categories(clean_data,
    dimensions=['arrondissement', 'top_lieu_1', 'top_lieu'],
    title="Classification des lieux",
    width=1000,
```

```
    height=800,
)
fig.show()

fig = px.parallel_categories(clean_data,
    dimensions=['top_libelle_francais', 'top_genre', 'top_espece',␣
 ↪'top_variete'],
    title="Classification des variétés d'arbres",
    width=1000,
    height=800,
)
fig.show()
```

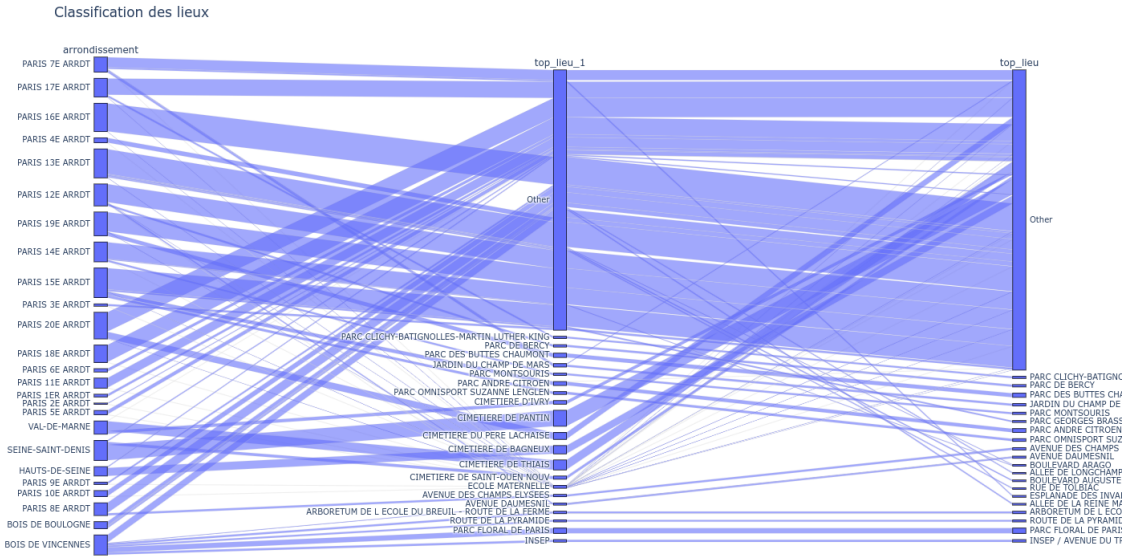

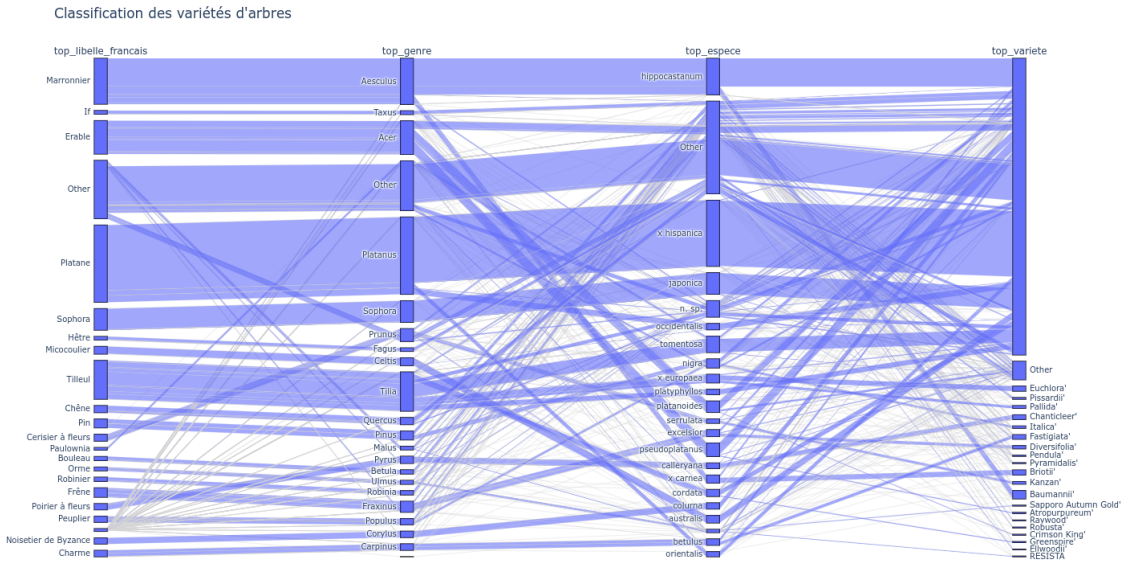

1.6 Améliorons la gestion des arbres

Nous allons ici nous appuyer sur des analyses statistiques et des graphiques afin de voir comment il serait possible d'améliorer le service de gestion des arbres de Paris.

1.6.1 Quels arbres faut-il mesurer à nouveau ?

Pour la suite de l'analyse, nous allons éliminer les données abberrantes ("outliers). Pour celà, nous allons utiliser le critère IQR. Nous allons considérer toutes les données de taille trop éloignées de la norme, ainsi que les valeurs égales à `0` comme des données aberrantes.

Nous allons dans un premier temps afficher une cartographie de ces arbres, car ceux-ci devront être mesurés à nouveau afin d'améliorer la fiabilité de la gestion de nos arbres. Nous allons ensuite considérer ces données comme nulles (`NaN`).

[10]:
```
# Let's work on a copy of our clean data.
data = clean_data.copy()

# First, let's consider zeros as NaN
data['circonference_cm'].where(data['circonference_cm'] > 0, inplace=True)
data['hauteur_m'].where(data['hauteur_m'] > 0, inplace=True)

# Let's compute the InterQuartile range in order to identify outliers
quartiles = data[['circonference_cm', 'hauteur_m']].quantile([0.25, 0.75])
iqr = quartiles.loc[0.75]-quartiles.loc[0.25]
limits = pd.DataFrame({
    'circonference_cm': [
```

```
        max(0, quartiles.loc[0.25,'circonference_cm'] - 1.5 *␣
↪iqr['circonference_cm']), # min
        quartiles.loc[0.75,'circonference_cm'] + 1.5 * iqr['circonference_cm'],␣
↪# max
    ],
    'hauteur_m': [
        max(0, quartiles.loc[0.25,'hauteur_m'] - 1.5 * iqr['hauteur_m']), # min
        quartiles.loc[0.75,'hauteur_m'] + 1.5 * iqr['hauteur_m'], # max
    ]
}, index=['min', 'max'])

display(quartiles, limits)
```

	circonference_cm	hauteur_m
0.25	45.0	6.0
0.75	123.0	14.0

	circonference_cm	hauteur_m
min	0.0	0.0
max	240.0	26.0

Nous voyons qu'un arbre "normal" aura : - une circonférence comprise entre 0 et 240 cm - une hauteur comprise entre 0 et 26 m

Nous allons maintenant visualiser où sont situé ces arbres "anormaux" (outliers), afin de planifier les tournées de mesure de ces arbres.

[11]:
```
# outliers are the trees outside the IQR range
outliers = clean_data[
    ( clean_data['circonference_cm'] <= limits.loc['min','circonference_cm'] )
    | ( clean_data['circonference_cm'] >= limits.loc['max','circonference_cm'] )
    | ( clean_data['hauteur_m'] <= limits.loc['min','hauteur_m'] )
    | ( clean_data['hauteur_m'] >= limits.loc['max','hauteur_m'] )
]
```

[12]:
```
# Count trees per burrough
count_per_arrondissement = outliers['arrondissement'].value_counts().head(20)

# resize figure
plt.figure(figsize=(16,9))

# plot horizontal bar chart
plt.barh(
    y=count_per_arrondissement.index,
    width=count_per_arrondissement.values,
)

# add labels for the value of each bar
for index, value in enumerate(count_per_arrondissement):
```

```
    plt.text(y=index , x=value+1 , s=f"{value}")

# add title and labels
plt.xlabel("Nombre d'arbres")
plt.ylabel("Arrondissement")
plt.title(f"Nombre d'arbres à re-mesurer par arrondissement.\nTOTAL = {␣
 ↪len(outliers) }")

# display the figure
plt.show()
```

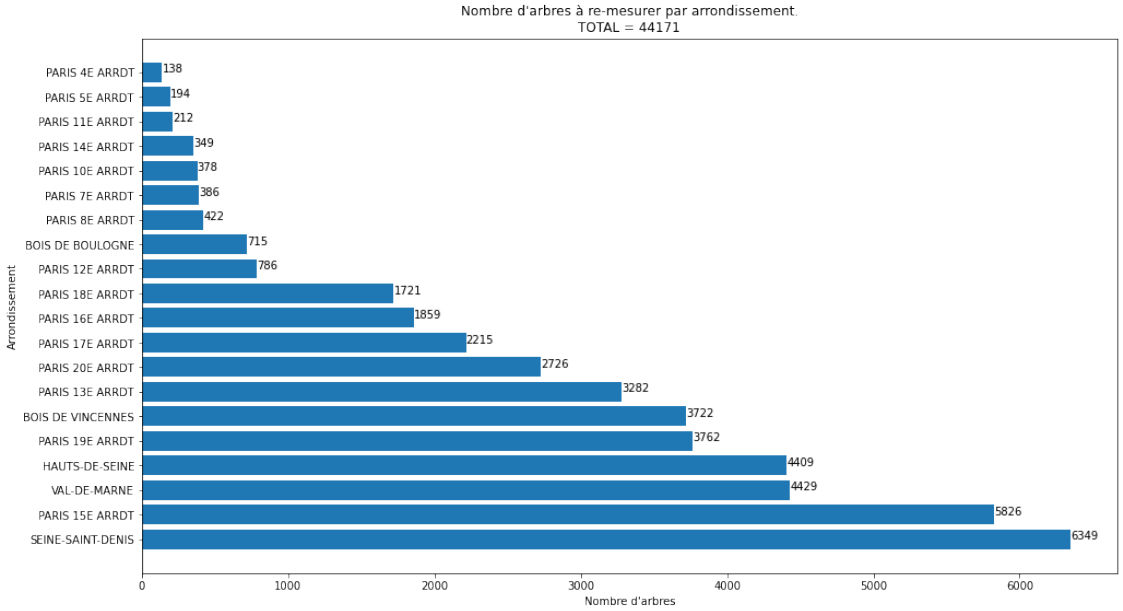

[13]:
```
# Display the outliers on a map
fig = px.density_mapbox(outliers,
    lat='geo_point_2d_a', lon='geo_point_2d_b',
    hover_data=['circonference_cm', 'hauteur_m', 'arrondissement', 'lieu',␣
 ↪'domanialite'],
    radius=2,
    zoom=10,
    mapbox_style="open-street-map",
    title="Localisation des arbres à re-mesurer",
    width=1000,
    height=800,
)
fig.show()
```

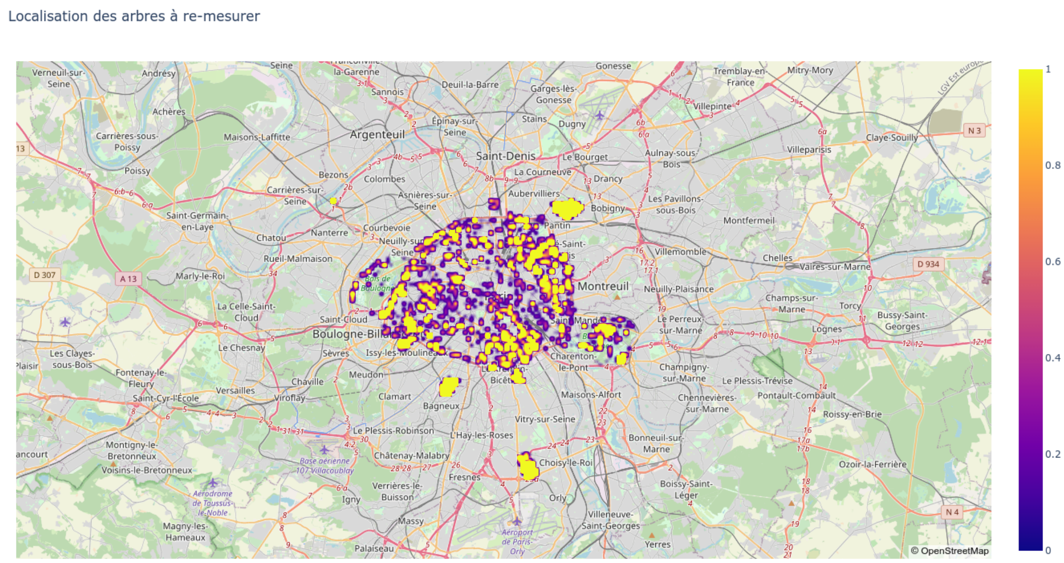

Nous voyons ici la carte des 44171 arbres qu'il faudrait mesurer à nouveau.

En attendant que ces arbres soient mesurés à nouveau, nous allons maintenant les ignorer dans nos prochaines analyses : passer à `NaN` les valeurs aberrantes.

[14]:
```
# set to NaN data that are outside the range
for col in ['circonference_cm', 'hauteur_m']:
    clean_data[col] = clean_data[col].where((
        ( limits.loc['min', col] < clean_data[col] )
        & ( clean_data[col] < limits.loc['max', col] )
    ))
```

1.6.2 Quels arbres ont un développement anormal ?

Afin de gérer efficacement le patrimoine arboricole, il faut être capable de détecter les potentiels arbres malades ou qui ont des problèmes de développement.

Nous allons ici chercher quels abres semblent avoir un développement anormal et donc qu'il faudrait contrôler en priorité.

[15]:
```
# Let's remove empty values
clean_data_dropna = clean_data.dropna(subset=['circonference_cm', 'hauteur_m',␣
 ↪'stade_developpement', 'top_libelle_francais'])

sns.jointplot(data=clean_data_dropna,
    x="circonference_cm",
    y="hauteur_m",
    hue="stade_developpement",
```

```
    hue_order=['Jeune', 'Jeune Adulte', 'Adulte', 'Mature'],
    height=10,
)
```

[15]: <seaborn.axisgrid.JointGrid at 0x7fe9cbb2e160>

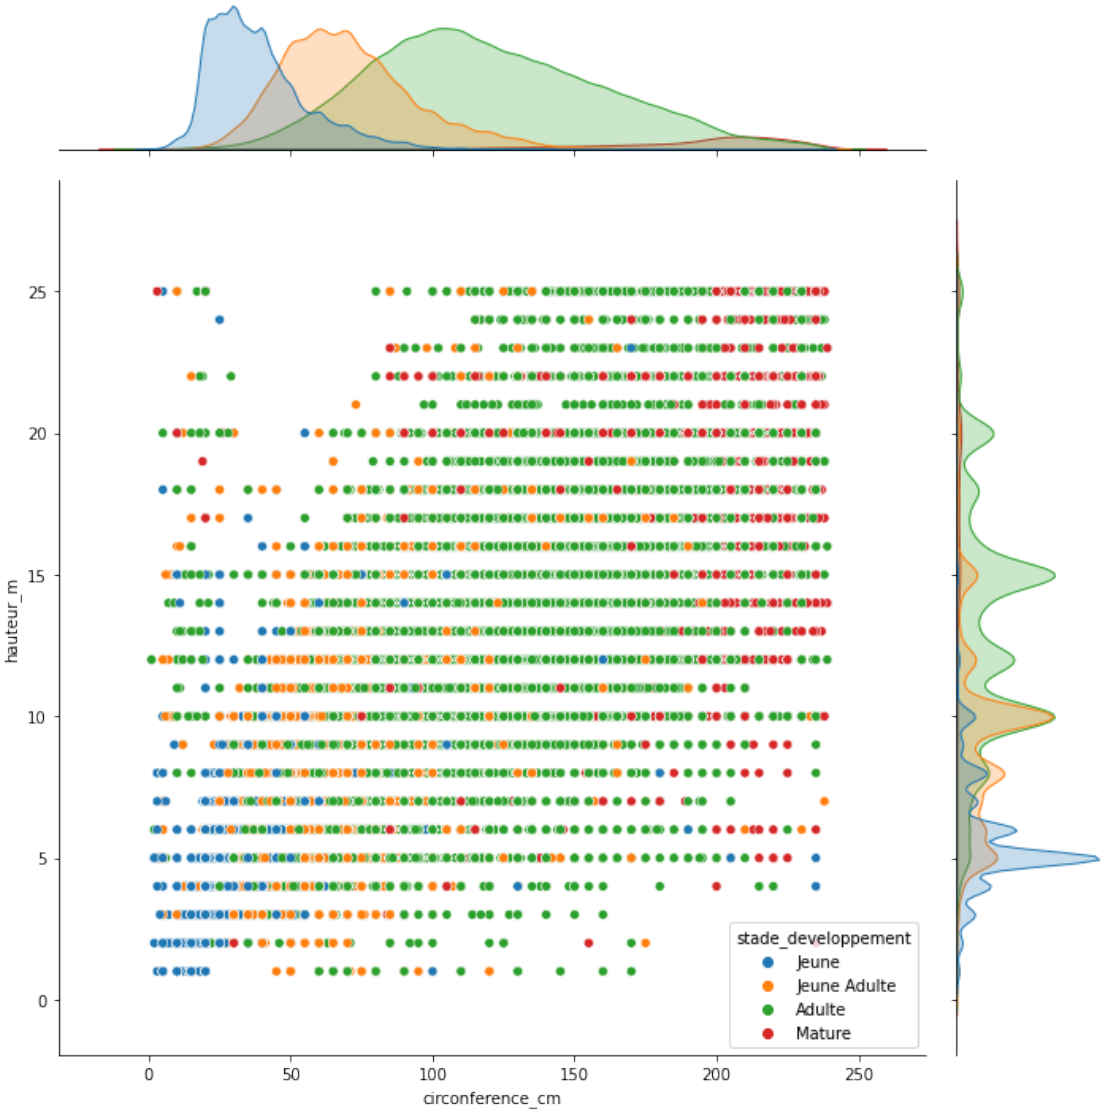

[16]:
```
# Display box plots for trees height and circumference per development stage
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16,8))
ax1.set_title("Hauteur par stade de développement")
ax2.set_title("Circonférence par stade de développement")

sns.boxplot(data=clean_data_dropna,
```

```
    x="stade_developpement",
    y="hauteur_m",
    order=['Jeune', 'Jeune Adulte', 'Adulte', 'Mature'],
    ax=ax1,
)

sns.boxplot(data=clean_data_dropna,
    x="stade_developpement",
    y="circonference_cm",
    order=['Jeune', 'Jeune Adulte', 'Adulte', 'Mature'],
    ax=ax2,
)
```

[16]:
```
<AxesSubplot:title={'center':'Circonférence par stade de développement'},
xlabel='stade_developpement', ylabel='circonference_cm'>
```

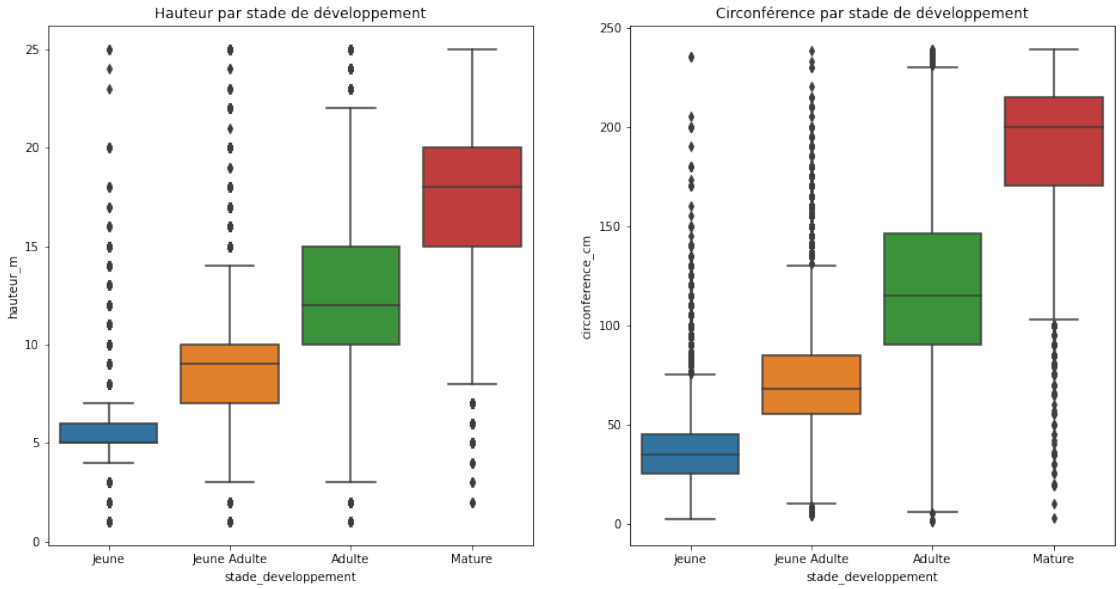

Nous voyons qu'il y a des arbres qui ont une taille anormale par rapport à leur stade de développement. Il faudrait contrôler leur santé et leur apporter les soins nécessaires (engrais, arrosage, traitements, …).

1.6.3 Où sont situés les arbres qui vont nécessiter le plus d'entretien ?

Plus un arbre est grand, plus il nécessitera de techniciens, de temps, de matériel, d'arrosage et de produits pour son entretien. Maintenant que nous avons éliminé les valeurs aberrantes, nous allons cartographier les arbres en les pondérant avec leur hauteur.

[17]:
```
# Display the trees on a map, weighted by size
fig = px.density_mapbox(clean_data,
```

```
    lat='geo_point_2d_a', lon='geo_point_2d_b',
    z='hauteur_m',
    hover_data=['circonference_cm', 'hauteur_m', 'arrondissement', 'lieu',␣
↪'domanialite'],
    radius=2,
    zoom=10,
    mapbox_style="open-street-map",
    title="Localisation des arbres nécessitant le plus de moyens",
    width=1000,
    height=800,
)
fig.show()
```

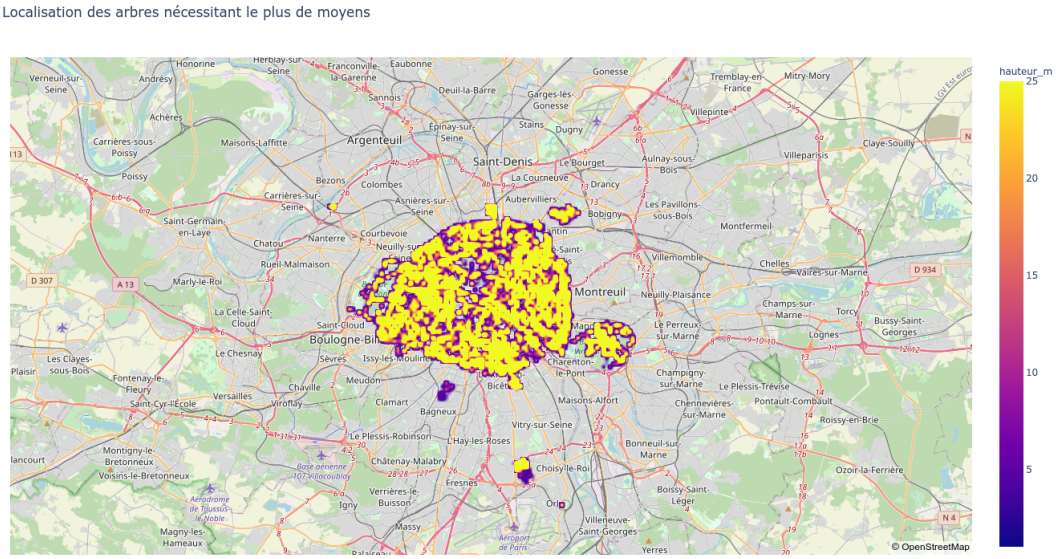

1.6.4 Quels sont les arbres les plus plantés actuellement ?

Nous allons travailler sur les données de catégories d'arbes, en se limitant aux valeurs les plus représentatives. Nous allons chercher à observer quel sont les types d'arbres les plus représentés selon leur type, et leur localisation.

[18]:
```
# Visualize repartition of type of trees
freq = clean_data['top_libelle_francais'].value_counts()
fig = px.pie(freq,
    names=freq.index,
    values=freq.values,
    title="Types d'arbres",
)
```

```
fig.update_traces(
    textposition='inside',
    textinfo='percent+label'
)
fig.show()
```

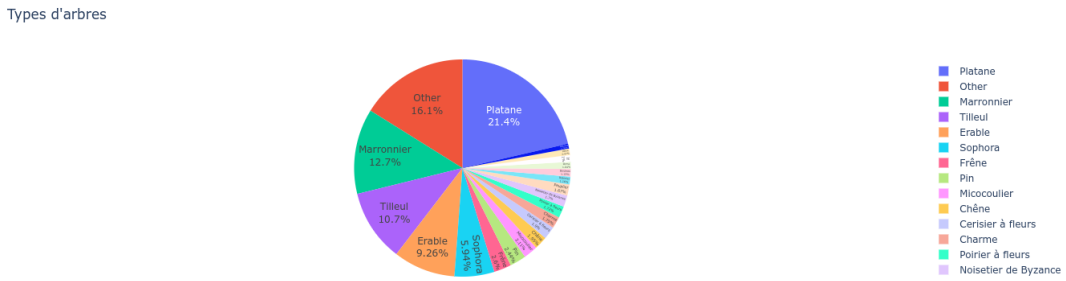

Nous voyons ici que seules 4 essences d'abres représentent plus de 50% des arbres plantés. Cette information est importante pour adapter le matériel et les produits nécessaires à l'enretien des arbres. Cette information montre aussi qu'il pourrait y avoir un problème diversité des essences et donc de résilience du parc arboricole de Paris.

[19]:
```
# Most common trees per burrough
table = clean_data.pivot_table(
    values='id',
    index='arrondissement',
    columns='top_libelle_francais',
    aggfunc='count',
    observed=True,
)
fig = px.imshow(table,
    title="Type d'arbre par arrondissement",
    width=1000,
    height=800,
)
fig.show()
```

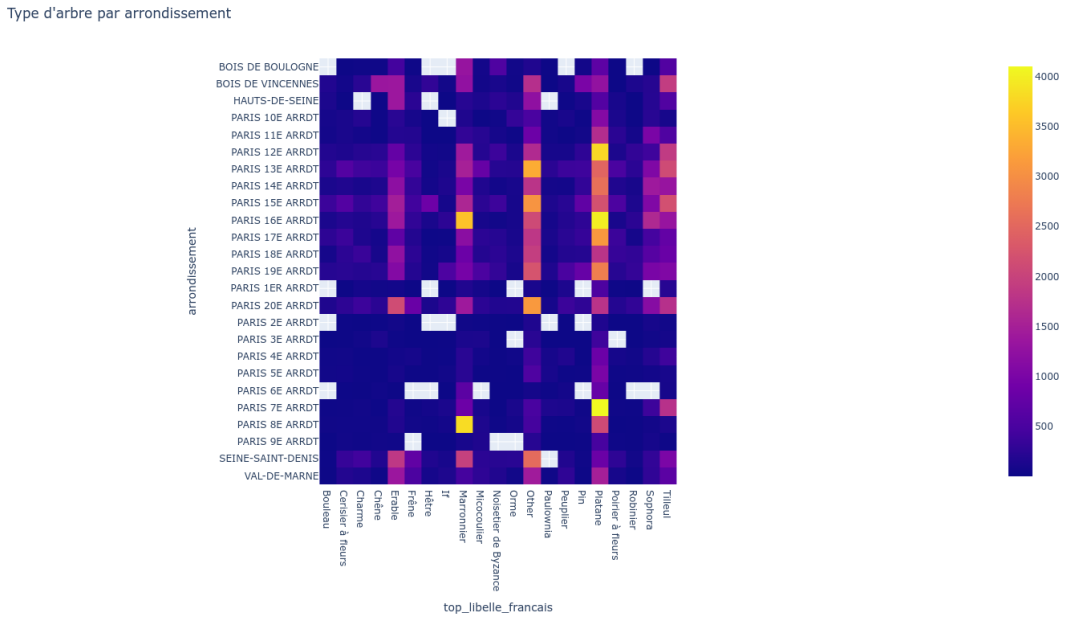

Nous voyons ici que nous avons beaucoup de peupliers, notamment dans le 7ème, le 12ème et le 16ème, ainsi que des marroniers dans le 8ème et le 16ème arrondissement. Cette information permet de dimensionner et répartir géographiquement les équipes et le matériel en fonction des types d'arbres plantés dans chaque arrondissement.

[20]:
```
# Most common trees per age
table = clean_data.pivot_table(
    values='id',
    index='stade_developpement',
    columns='top_libelle_francais',
    aggfunc='count',
    observed=True,
)
fig = px.imshow(table,
    title="Type d'arbre par stade de développement",
    width=1000,
    height=400,
)
fig.show()
```

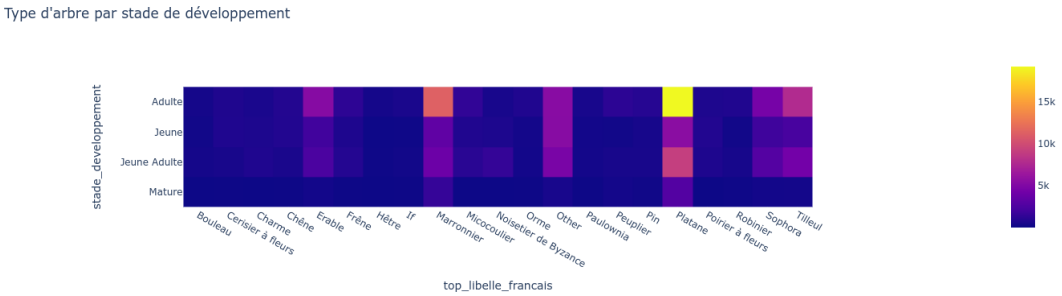

Nous voyons ici que la plupart des arbres sont des platanes adultes. Cette information permet d'optimiser les achats et le stockage du materiel et des produits adaptés spécifiquement à l'entretien de ces arbres.